SMART MATCH

Ruslan Gatiatullin – team lead

Ivan Savelev

Oleg Shchendrigin

Ilya Grigorev

OUR PROJECT

Smart Match is an intelligent system designed to automate genealogical research. For this project, we focus on a critical subtask: extracting structured information from scanned historical metrical books (birth, marriage, and death records) using OCR and information extraction techniques.

SIMPLIFIED PIPELINE

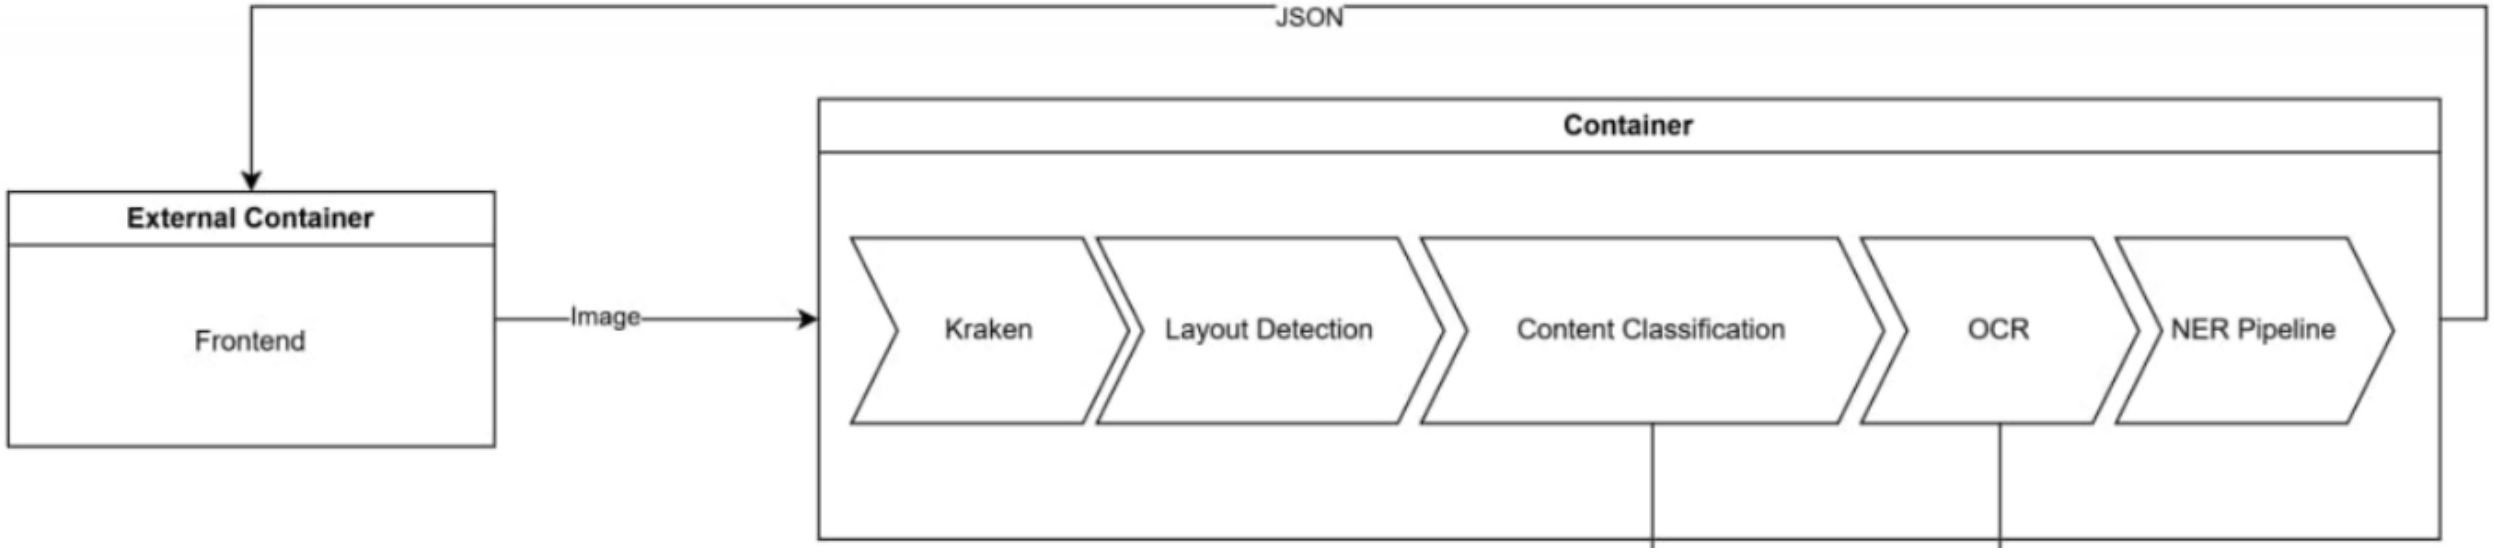

COMPLETE PIPELINE

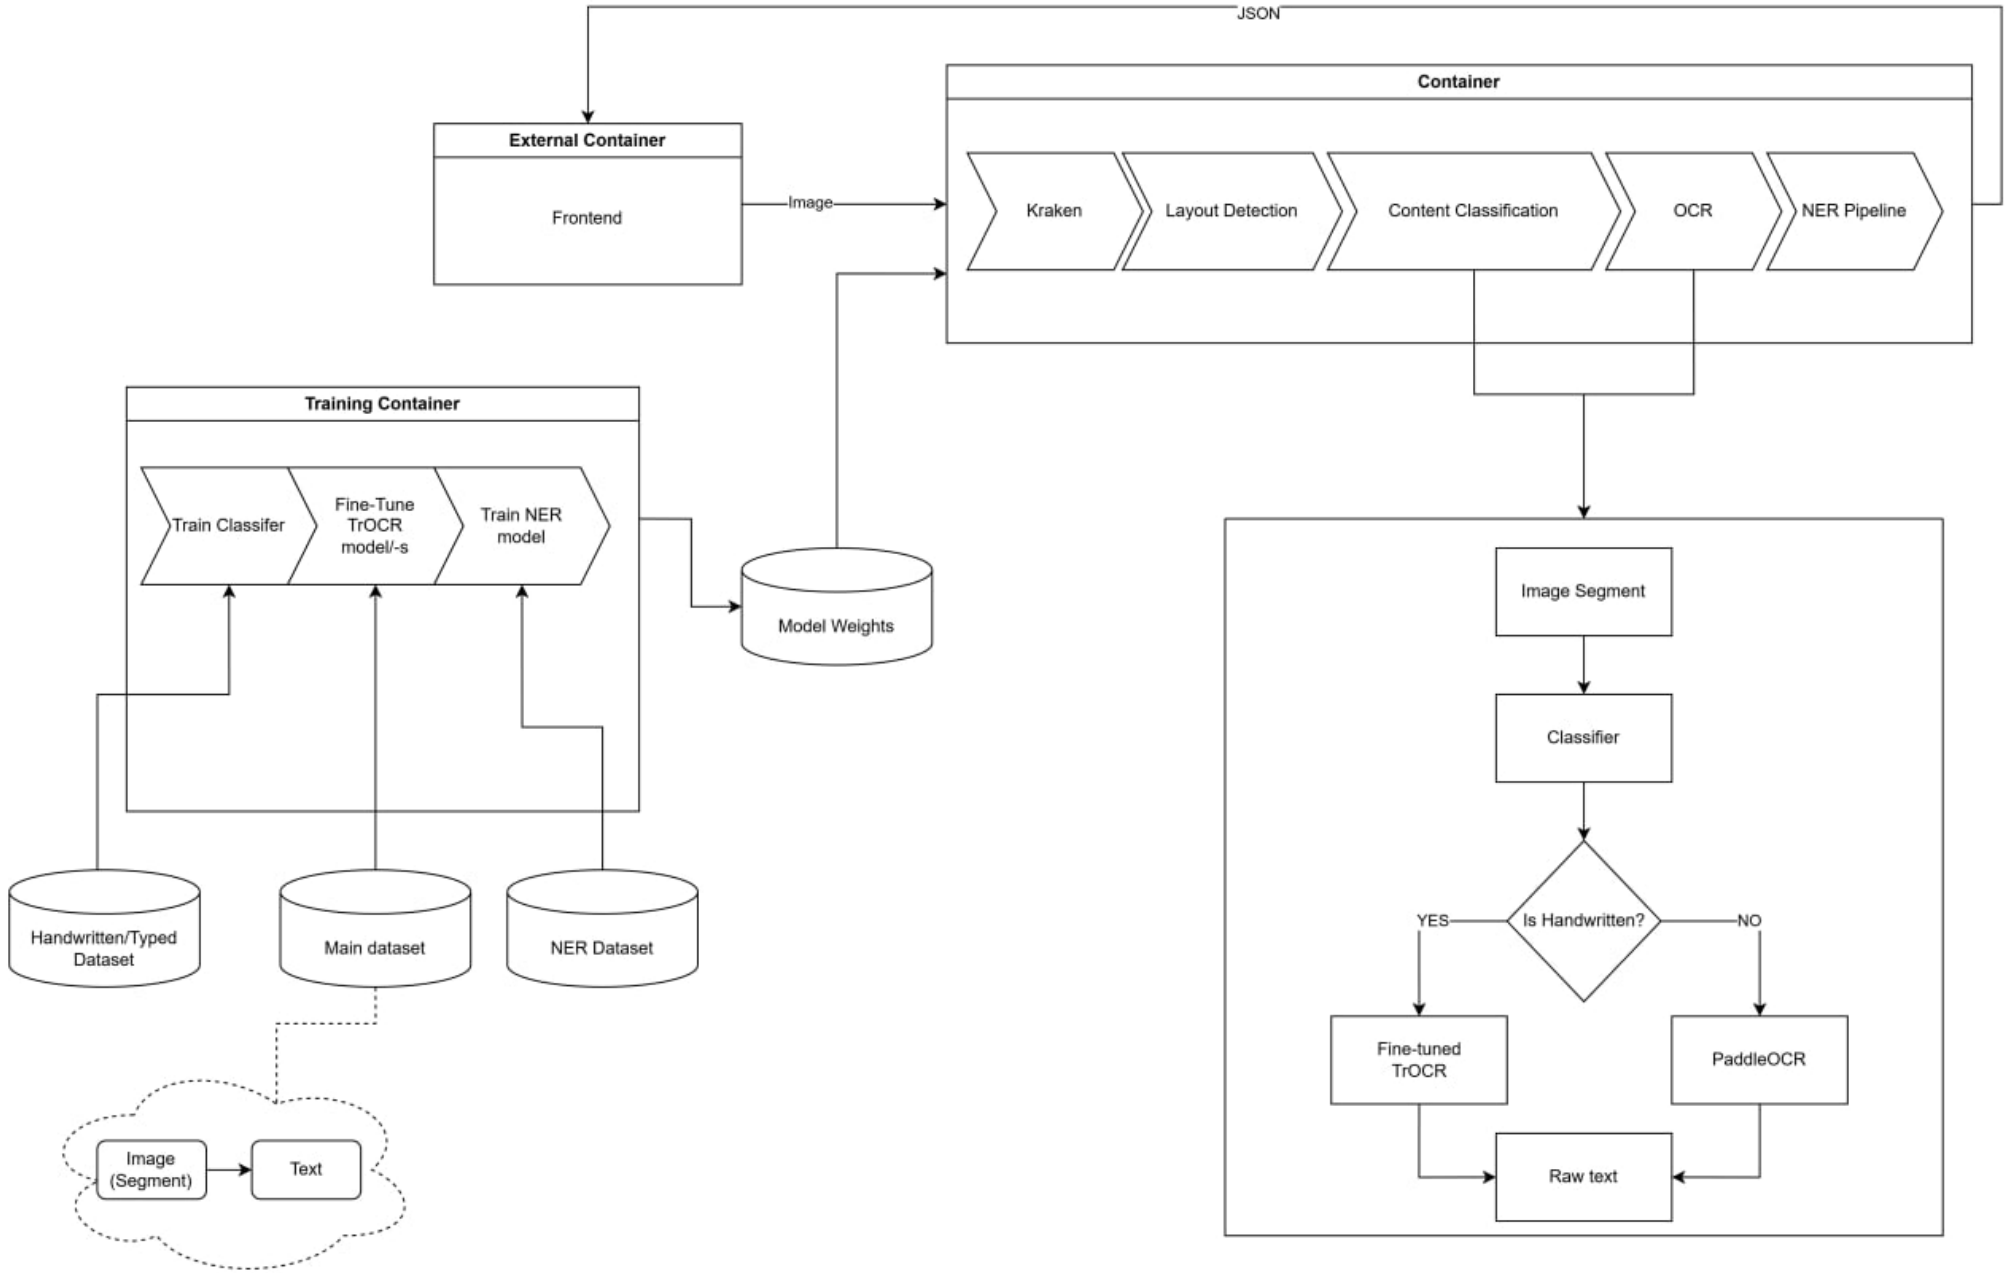

1) PREPROCESSING

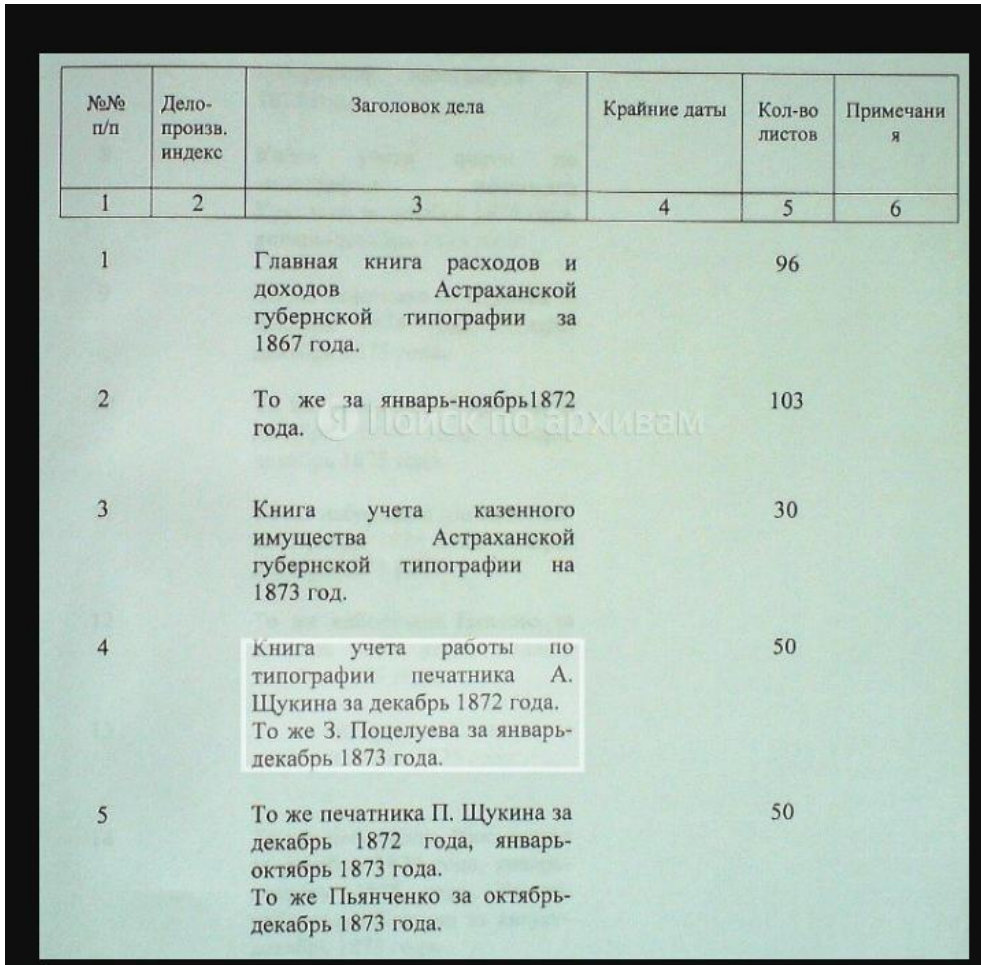

№№ п/п	Дело-произв. индекс	Заголовок дела	Крайние даты	Кол-во листов	Примечания
1	2	3	4	5	6
1		Главная книга расходов и доходов Астраханской губернской типографии за 1867 года.		96	
2		То же за январь-ноябрь1872 года.		103	
3		Книга учета казенного имущества Астраханской губернской типографии на 1873 год.		30	
4		Книга учета работы по типографии печатника А. Щукина за декабрь 1872 года. То же З. Поцелуева за январь-декабрь 1873 года.		50	
5		То же печатника П. Щукина за декабрь 1872 года, январь-октябрь 1873 года. То же Пьянченко за октябрь-декабрь 1873 года.		50	

Поиск по архивам

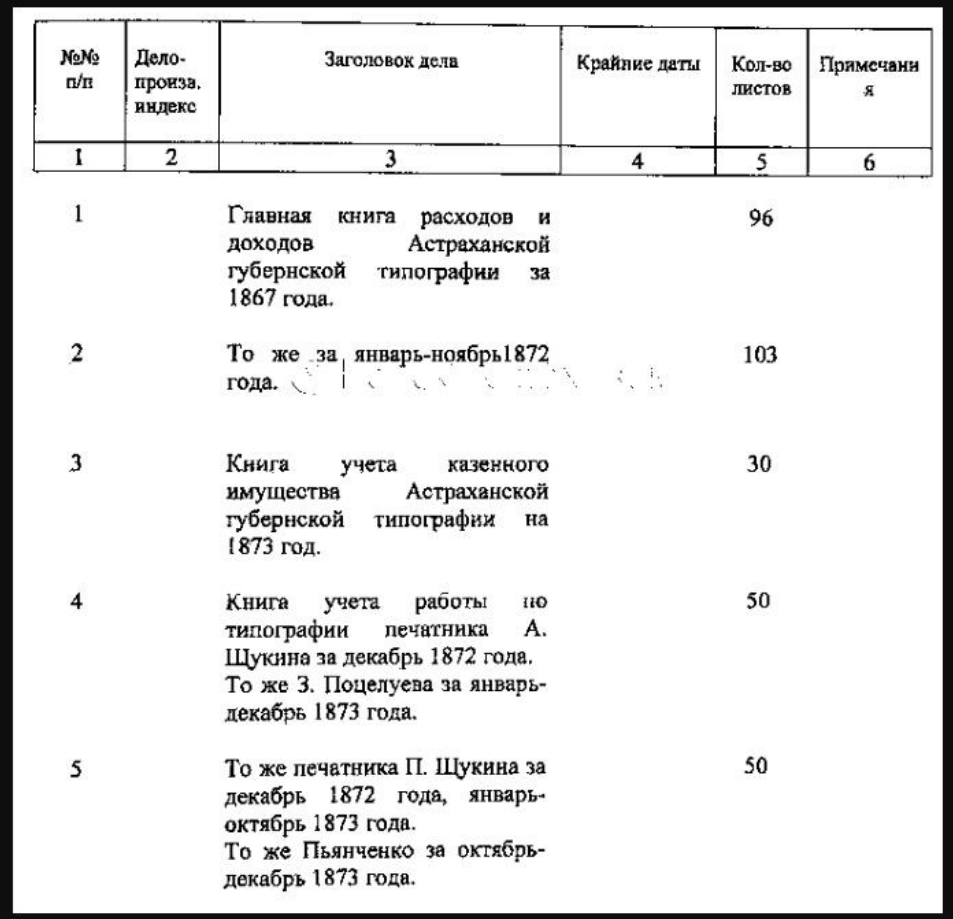

№№ п/п	Дело-произв. индекс	Заголовок дела	Крайние даты	Кол-во листов	Примечания
1	2	3	4	5	6
1		Главная книга расходов и доходов Астраханской губернской типографии за 1867 года.		96	
2		То же за январь-ноябрь1872 года.		103	
3		Книга учета казенного имущества Астраханской губернской типографии на 1873 год.		30	
4		Книга учета работы по типографии печатника А. Щукина за декабрь 1872 года. То же З. Поцелуева за январь-декабрь 1873 года.		50	
5		То же печатника П. Щукина за декабрь 1872 года, январь-октябрь 1873 года. То же Пьянченко за октябрь-декабрь 1873 года.		50	

2) LAYOUT DETECTION

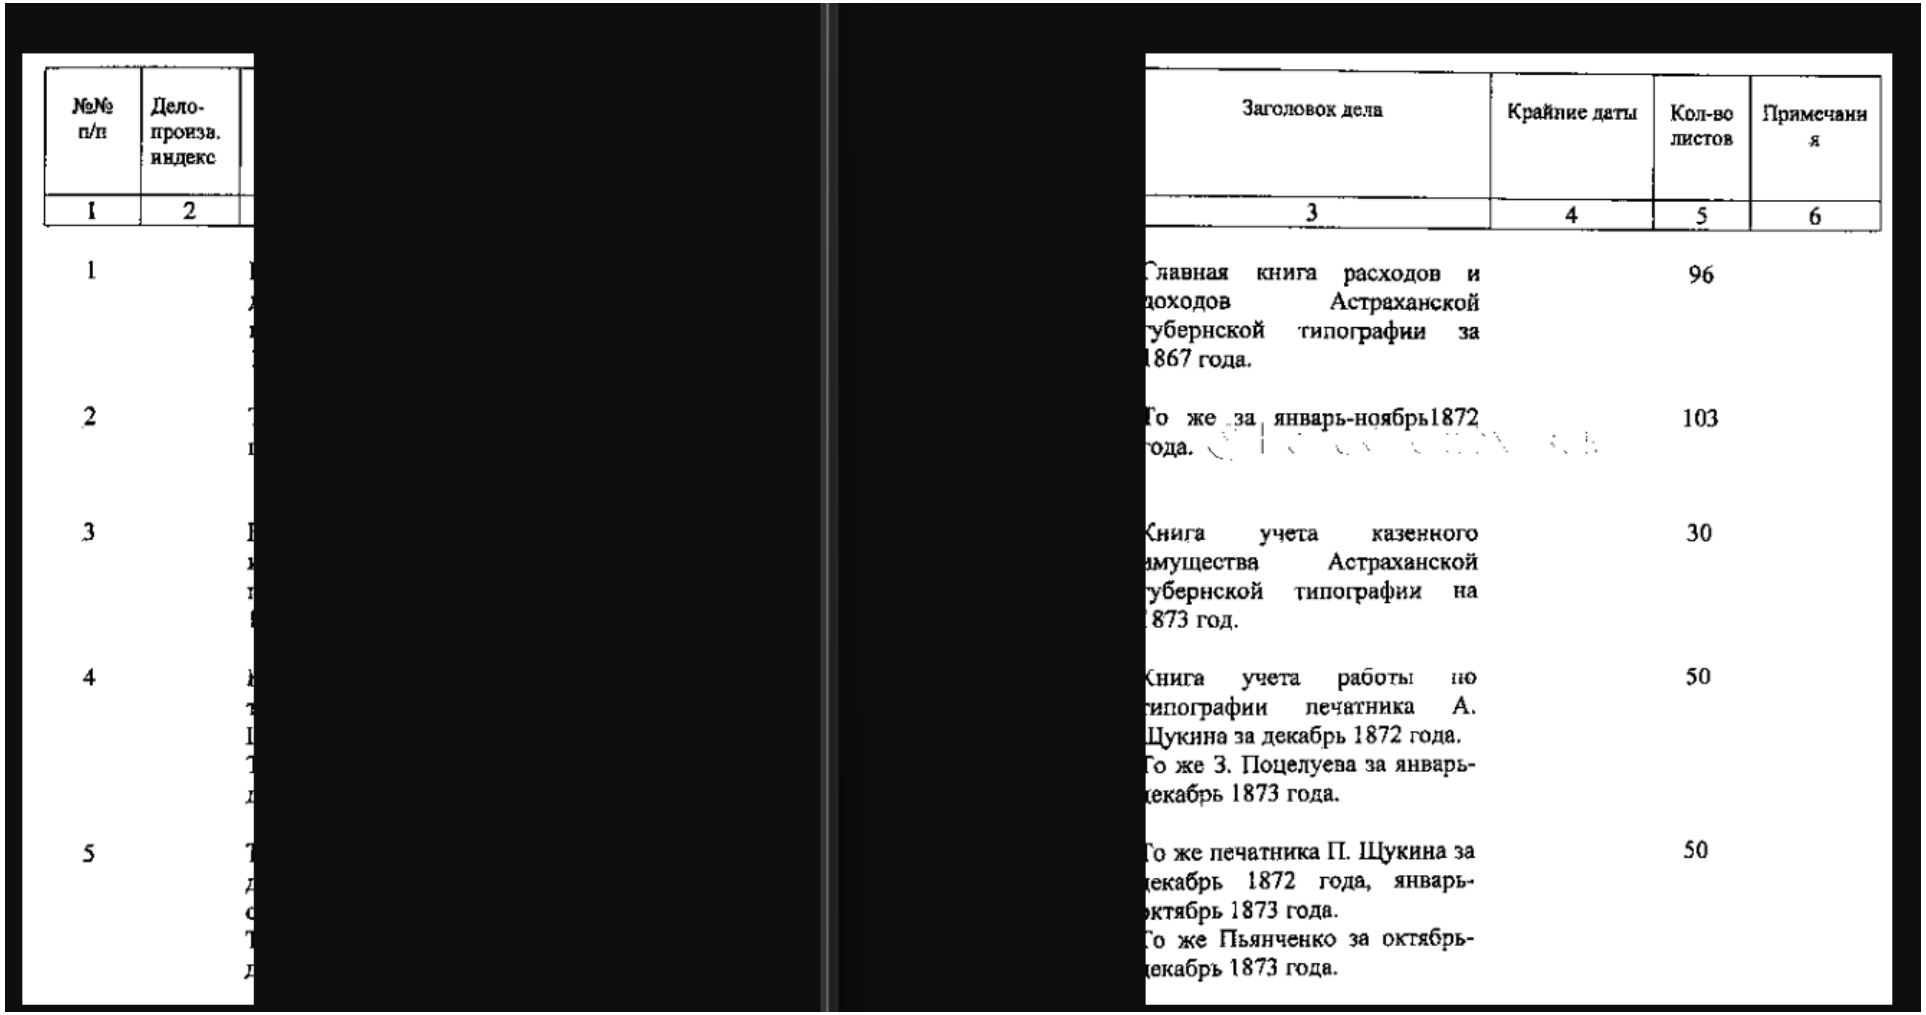

№№ п/п	Дело-произв. индекс	Заголовок дела	Крайние даты	Кол-во листов	Примечания
1	2	3	4	5	6
1		Главная книга расходов и доходов Астраханской губернской типографии за 1867 года.		96	
2		То же за январь-ноябрь1872 года.		103	
3		Книга учета казенного имущества Астраханской губернской типографии на 1873 год.		30	
4		Книга учета работы по типографии печатника А. Щукина за декабрь 1872 года. То же З. Поцелуева за январь-декабрь 1873 года.		50	
5		То же печатника П. Щукина за декабрь 1872 года, январь-октябрь 1873 года. То же Пьянченко за октябрь-декабрь 1873 года.		50	

3) CONTENT CLASSIFICATION

Output

Classified 2 segment(s)

Classification JSON

```
03_classify/output/classification.json
```


```
[
  {
    "index": 1,
    "filename": "segment_001.png",
    "classification_label": 0,
    "classification_name": "printed"
  },
  {
    "index": 2,
    "filename": "segment_002.png",
    "classification_label": 0,
    "classification_name": "printed"
  }
]
```

4) OCR

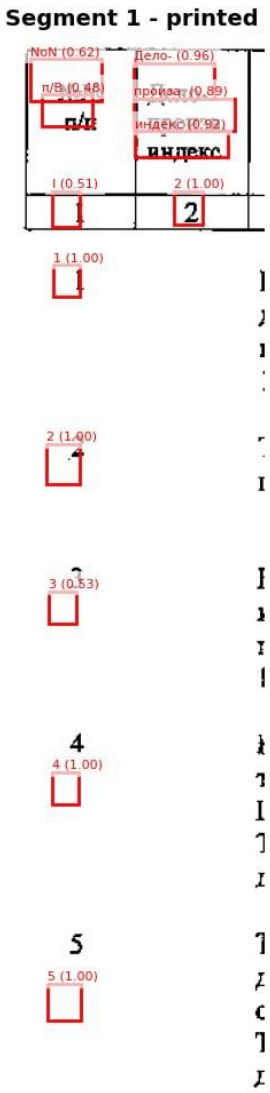
Segment 1 - printed

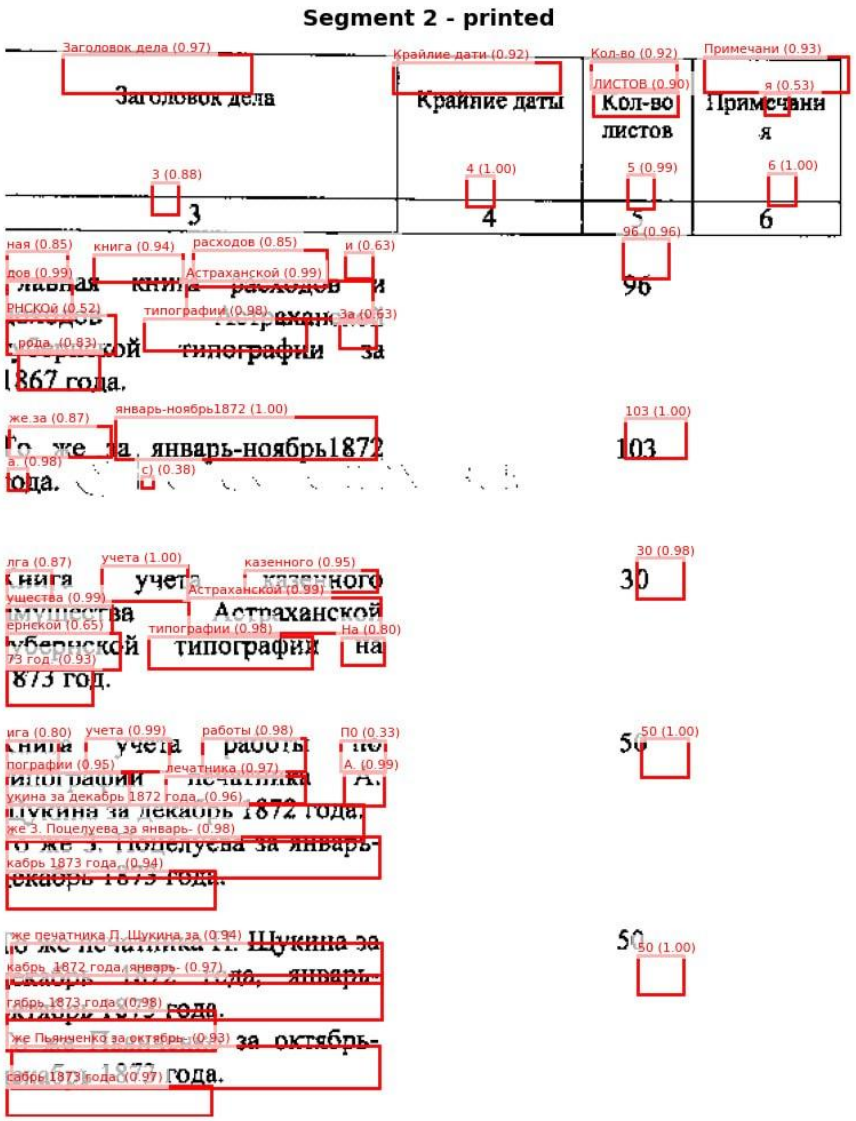
Segment 2 - printed
Заголовок дела
Крайние даты
Кол-во листов
Примечания
книга
расходов
Астраханской
типографии
за
1867 года.
январь-ноябрь1872
103
30
50

4) OCR


```
{
  "segments": [
    {
      "index": 1,
      "filename": "segment_001.png",
      "classification_label": 0,
      "classification_name": "printed",
      "ocr": {
        "status": "done",
        "engine": "paddleocr",
        "device": "gpu:0",
        "text": "NoN\nДело-\nп/В\nпроиза.\пиндекс\nI\n2\n1\n2\n3\n4\n5",
        "confidence": 0.8248417029778162,
        "lines": [
          {
            "index": 1,
            "text": "NoN",
            "confidence": 0.6189376711845398,
            "box": [
              19,
              16,
              65,
              43
            ]
          },
          {
            "index": 2,
            "text": "Дело-",
            "confidence": 0.9559067487716675,
            "box": [
              86,
              19,
              138,
              42
            ]
          },
          {
            "index": 3,
            "text": "п/В",
            "confidence": 0.48029327392578125,
```

```
    {
      "index": 2,
      "filename": "segment_002.png",
      "classification_label": 0,
      "classification_name": "printed",
      "ocr": {
        "status": "done",
        "engine": "paddleocr",
        "device": "gpu:0",
        "text": "Заголовок дела\nКрайлие дати\nКол-во\nПримечани\nЛИСТОВ\ня\n3\n4\n5\n6\nная\ни\n96\nкнига\прасходов\пдов
        "confidence": 0.8916506688549833,
        "lines": [
          {
            "index": 1,
            "text": "Заголовок дела",
            "confidence": 0.9732092022895813,
            "box": [
              37,
              13,
              160,
              38
            ]
          },
          {
            "index": 2,
            "text": "Крайлие дати",
            "confidence": 0.917398989200592,
            "box": [
              252,
              18,
              361,
              38
            ]
          },
          {
            "index": 3,
            "text": "Кол-во",
            "confidence": 0.9247815012931824,
            "box": [
              381,
              17,
              437,
              35
            ]
          },
```

4) NAMED ENTITY RECOGNITION


```
"grouped": {
  "PER": [
    "Крайлие",
    "А.",
    {
      "first": "П",
      "last": "Шукин"
    },
    {
      "last": "Пьянченко"
    }
  ],
  "ORG": [
    "Астраханская РНСКО",
    "Астраханская ер",
    "На 73"
  ],
  "DATES": [
    {
      "year": 1872,
      "month": 11,
      "day": null
    },
    {
      "year": 1872,
      "month": 12,
      "day": null
    },
    {
      "year": 1873,
      "month": null,
      "day": null
    },
    {
      "year": 1872,
      "month": null,
      "day": null
    },
    {
      "year": 1873,
      "month": null,
      "day": null
    },
    {
      "year": 1873,
      "month": null,
      "day": null
    }
  ]
}
```


№№ п/п	Дело-произв. индекс	Заголовок дела	Крайние даты	Кол-во листов	Примечания
1	2	3	4	5	6
1		Главная книга расходов и доходов Астраханской губернской типографии за 1867 года.		96	
2		То же за январь-ноябрь1872 года.		103	
3		Книга учета казенного имущества Астраханской губернской типографии на 1873 год.		30	
4		Книга учета работы по типографии печатника А. Щукина за декабрь 1872 года. То же З. Поцелуева за январь-декабрь 1873 года.		50	
5		То же печатника П. Щукина за декабрь 1872 года, январь-октябрь 1873 года. То же Пьянченко за октябрь-декабрь 1873 года.		50	

4) NAMED ENTITY RECOGNITION

```
text = """
Динамика возобновления роста случаев COVID-19 в мире является поводом для серьезной обеспокоенности
– признал пресс-секретарь президента России Дмитрий Песков одиннадцатого сентября на брифинге в Москве.
Встреча с губернатором Санкт-Петербурга Александром Бегловым запланирована на 15.12.2024 в 10:00."""
```

```
Динамика возобновления роста случаев COVID-19 в мире является поводом
для серьезной обеспокоенности
– признал пресс-секретарь президента России Дмитрий Песков
                                        LOC—— PER——————————
одиннадцатого сентября на брифинге в Москве.
                                        LOC——
Встреча с губернатором Санкт-Петербурга Александром Бегловым
                       LOC————————————— PER———————————————
запланирована на 15.12.2024 в 10:00.
```


```
{
  "LOC": [
    "Россия",
    "Москва",
    "Санкт-Петербург"
  ],
  "PER": [
    {
      "first": "Дмитрий",
      "last": "Песков"
    },
    {
      "first": "Александр",
      "last": "Беглов"
    }
  ],
  "DATES": [
    {
      "YEAR": 2024,
      "MONTH": 12,
      "DAY": 15
    }
  ]
}
```

METRICS

5%

PRINTED OCR

ERROR CHARACTER RATE

34%

HANDWRITTEN OCR

ERROR CHARACTER RATE

15-20 S

AVRAGE EXECUTION TIME

METRICS

99%

HANDWRITTEN / PRINTED CLASSIFICATION ACCURACY

99%

HANDWRITTEN / PRINTED CLASSIFICATION F1

WHAT WE ARE USING

- Preprocessing - Kraken
- Layout detection – OpenCV and DBScan
- Printed/Handwritten text classification – PyTorch CNN
- Printed OCR –PaddleOCR
- Handwritten OCR – fine-tuned TrOCR
- NER – Natasha
- Backend - FastAPI

ADDITIONAL INFO

- Our fine-tuned TrOCR model can be easily replaced with a different one.
- Everything runs inside Docker containers and can be launched with a single command.
- GitHub: https://github.com/Stillah/Smart-Match

QUESTIONS